

Lab 8 - DuckDB

Objetivo

Comprender y aplicar el uso de DuckDB para realizar análisis analítico sobre grandes volúmenes de datos almacenados en archivos Parquet. Durante el laboratorio se construirá un flujo reproducible para descargar, organizar, consultar, transformar y visualizar información que crece progresivamente.

Además, se comparará el desempeño de distintas estrategias de acceso a los datos y se analizarán las ventajas de DuckDB para escenarios de análisis de datos a gran escala.

El caso

Imagine que forma parte de un equipo de análisis de datos que trabaja con información de viajes de taxi de la ciudad de Nueva York.

Los datos se reciben como archivos independientes y nuevos archivos se incorporan continuamente conforme se generan nuevos registros. El equipo necesita responder preguntas analíticas sin depender de un servidor de base de datos tradicional y debe mantener un proceso que pueda reproducirse cuando se incorporen nuevos datos.

Su tarea consiste en construir un flujo de trabajo utilizando DuckDB que permita consultar y analizar esta información de manera eficiente.

Para realizar el laboratorio se utilizará el conjunto de datos de viajes de taxi publicado por la *New York City Taxi & Limousine Commission (TLC)*.

Instrucciones generales

Cada equipo recibirá un repositorio base que contiene la estructura del proyecto y un ambiente de ejecución basado en Docker. El repositorio contendrá algunos scripts incompletos que deberán ser modificados durante el laboratorio.

El trabajo deberá realizarse mediante un fork del repositorio proporcionado por el docente. El fork será el repositorio utilizado para desarrollar y entregar el laboratorio.

La investigación debe ser reproducible, por lo que:

- todo el código desarrollado deberá mantenerse versionado;
- los datos no deberán almacenarse dentro del repositorio Git;

- los scripts deberán permitir reproducir el proceso de descarga y preparación de los datos;
- las consultas SQL utilizadas deberán quedar documentadas;
- cualquier transformación realizada sobre los datos deberá quedar registrada;
- el repositorio deberá contener instrucciones suficientes para reproducir el trabajo.

Los archivos descargados durante el laboratorio deberán almacenarse en los directorios definidos por el repositorio.

Estructura del proyecto

Al iniciar el laboratorio encontrará una estructura similar a:

```
lab8-duckdb/  
|  
+-- data/  
|   +-- raw/  
|   +-- processed/  
|  
+-- notebooks/  
|  
+-- scripts/  
|  
+-- sql/  
|  
+-- docs/  
|  
+-- Dockerfile  
+-- docker-compose.yml  
+-- README.md
```

Analice esta estructura antes de comenzar a modificar los archivos y explique cuál considera que es el propósito de cada directorio.

Ejercicio 1

Preparación del ambiente

- 1.1. Realice un fork del repositorio proporcionado por el docente.
- 1.2. Clone su fork y levante el ambiente utilizando Docker Compose.
- 1.3. Verifique que los servicios proporcionados por el repositorio funcionen correctamente.
- 1.4. Identifique qué herramientas se encuentran disponibles dentro del ambiente.
- 1.5. Documente en el README.md el procedimiento utilizado para levantar el ambiente.
- 1.6. Explique por qué utilizar un ambiente reproducible resulta importante para un proyecto de análisis de datos.

Ejercicio 2

Desarrollo del sistema de descarga

El repositorio contiene un script inicial para descargar los datos. Sin embargo, el script está deliberadamente incompleto.

Su responsabilidad será modificarlo para que pueda descargar los datos requeridos por el laboratorio.

Inicialmente deberá trabajar únicamente con:

- taxis amarillos (*Yellow Taxi*);
- taxis verdes (*Green Taxi*);
- datos correspondientes al año 2026.

- 2.1. Analice el script proporcionado y determine qué partes deben ser modificadas.
- 2.2. Modifique el script para que pueda obtener automáticamente todos los archivos correspondientes a taxis amarillos y verdes del año 2026.
- 2.3. El script deberá almacenar los archivos descargados en la estructura de directorios establecida por el proyecto.
- 2.4. El script no deberá volver a descargar un archivo que ya exista localmente.

2.5. Ejecute el script y verifique que todos los archivos esperados hayan sido obtenidos correctamente.

2.6. Documente los cambios realizados al script.

2.7. Explique cómo determinó que el conjunto de datos descargado está completo.

Ejercicio 3

Consultas directas sobre archivos Parquet

En este ejercicio deberá comenzar a utilizar DuckDB para consultar los datos sin realizar una importación previa a una tabla.

Utilice DuckDB para realizar una exploración inicial de los archivos Parquet descargados.

3.1. Determine la cantidad de archivos disponibles.

3.2. Determine la cantidad de registros disponibles.

3.3. Identifique las columnas presentes en los archivos.

3.4. Determine los tipos de datos de las columnas.

3.5. Obtenga una muestra de los registros.

3.6. Identifique posibles problemas de calidad de datos que puedan observarse durante la exploración inicial.

3.7. Realice las consultas necesarias utilizando directamente los archivos Parquet.

3.8. Para cada consulta utilizada, documente:

- la consulta SQL;
- el objetivo de la consulta;
- los archivos utilizados como fuente;
- el resultado obtenido;
- cualquier decisión tomada a partir del resultado.

3.9. Explique qué significa consultar directamente un archivo Parquet y por qué esta estrategia puede ser útil cuando el volumen de datos es grande.

Ejercicio 4

Análisis exploratorio utilizando DuckDB

Utilizando DuckDB, realice un análisis exploratorio de los datos disponibles.

El análisis deberá considerar, como mínimo:

- comportamiento temporal de los viajes;
- características de los viajes;
- diferencias entre taxis amarillos y verdes;
- variables relacionadas con el pago;
- distribución de los valores relevantes;
- posibles valores atípicos o inconsistencias.

No se proporcionará un conjunto predeterminado de consultas.

Las preguntas analíticas deberán ser planteadas por cada equipo y deberán estar justificadas a partir de las características del conjunto de datos.

- 4.1. Plantee las preguntas que desea responder.
- 4.2. Construya las consultas necesarias para responderlas.
- 4.3. Documente las consultas utilizadas.
- 4.4. Explique los resultados obtenidos.
- 4.5. Identifique al menos tres hallazgos relevantes encontrados durante el análisis.

Ejercicio 5

Incorporación de datos adicionales

Hasta este momento el sistema ha trabajado únicamente con información de 2026.

Ahora deberá ampliar el sistema para incorporar los datos correspondientes al año 2024.

El nuevo conjunto de datos no será entregado por el docente. El sistema construido durante el ejercicio anterior deberá ser capaz de obtenerlo directamente desde la fuente original.

- 5.1. Modifique el sistema de descarga para incorporar los datos de taxis amarillos y verdes correspondientes al año 2024.
- 5.2. El sistema deberá conservar los archivos de 2026 que ya hayan sido descargados.
- 5.3. El sistema no deberá volver a descargar archivos que ya existan.
- 5.4. Ejecute nuevamente el proceso de descarga.
- 5.5. Verifique que los nuevos archivos fueron incorporados correctamente.
- 5.6. Compruebe mediante DuckDB que ahora es posible consultar conjuntamente la información de 2024 y 2026.
- 5.7. Determine si las consultas desarrolladas anteriormente necesitan ser modificadas para trabajar con el nuevo conjunto de archivos.
- 5.8. Documente las consultas utilizadas para validar la incorporación del año 2024.
- 5.9. Explique qué características del diseño de su sistema permiten incorporar nuevos archivos sin tener que modificar todo el flujo de análisis.

Ejercicio 6

Parquet versus tablas DuckDB

Una de las características importantes de DuckDB es que permite trabajar directamente con archivos Parquet. Sin embargo, también es posible materializar los datos dentro de una base de datos DuckDB.

En este ejercicio comparará ambas estrategias.

- 6.1. Utilice DuckDB para consultar directamente los archivos Parquet.
- 6.2. Cree una tabla DuckDB a partir del conjunto de datos correspondiente a los años descargados.
- 6.3. Seleccione un conjunto de consultas representativas del análisis realizado anteriormente.
- 6.4. Ejecute las mismas consultas utilizando:
 - los archivos Parquet directamente;
 - la tabla materializada en DuckDB.
- 6.5. Registre el tiempo de ejecución de cada consulta.

- 6.6. Repita el análisis utilizando diferentes cantidades de datos y observe cómo cambia el comportamiento.
- 6.7. Organice los resultados del benchmark en una tabla.
- 6.8. Documente las consultas utilizadas en el benchmark.
- 6.9. Analice los resultados y explique las diferencias observadas.
- 6.10. Discuta en qué escenarios considera apropiado consultar directamente archivos Parquet y en cuáles sería conveniente materializar una tabla en DuckDB.

Ejercicio 7

Construcción de indicadores y visualización

Para este ejercicio deberá construir un tablero de análisis basado en los datos disponibles.

No se proporcionarán indicadores específicos.

Cada equipo deberá identificar los indicadores que considere más relevantes para comprender el comportamiento de los viajes de taxi.

Construya al menos 6 indicadores diferentes.

Cada indicador deberá:

- responder una pregunta de análisis;
- utilizar datos provenientes de DuckDB;
- estar respaldado por una consulta SQL;
- ser visualizado mediante la herramienta proporcionada;
- incluir una interpretación.

7.1. Defina al menos diez preguntas que considere relevantes para el análisis.

7.2. Diseñe los indicadores que permitirán responder dichas preguntas.

7.3. Construya las consultas SQL necesarias.

7.4. Construya las visualizaciones correspondientes.

7.5. Organice las visualizaciones en un tablero que permita analizar los resultados de manera conjunta.

- 7.6. Justifique la selección de cada indicador.
- 7.7. Documente las consultas utilizadas para construir cada indicador.
- 7.8. Interprete los resultados obtenidos y discuta los principales hallazgos encontrados.

Ejercicio 8

Incorporación de datos de 2025 y análisis completo

Amplíe nuevamente el sistema de descarga para incorporar los datos correspondientes al año 2025.

Al finalizar este ejercicio, el sistema deberá permitir trabajar de manera reproducible con:

- taxis amarillos de 2024, 2025 y 2026;
- taxis verdes de 2024, 2025 y 2026.

- 8.1. Modifique el sistema de descarga para incorporar los nuevos datos.
- 8.2. Verifique que los archivos previamente descargados no sean descargados nuevamente.
- 8.3. Compruebe que las consultas desarrolladas continúan funcionando sobre el conjunto de datos ampliado.
- 8.4. Actualice los indicadores y visualizaciones para considerar los tres años.
- 8.5. Analice la evolución de los indicadores seleccionados a través del tiempo.
- 8.6. Identifique al menos tres cambios o patrones que se hagan visibles al considerar conjuntamente 2024, 2025 y 2026.
- 8.7. Documente las consultas utilizadas para obtener los resultados.

Ejercicio 9

Discusión

Con base en el trabajo realizado, responda:

- 9.1. ¿Qué características de DuckDB resultaron más útiles durante el laboratorio?
- 9.2. ¿Qué ventajas y limitaciones encontró al consultar directamente archivos Parquet?

- 9.3. ¿Qué ventajas y limitaciones observó al utilizar tablas materializadas en DuckDB?
- 9.4. ¿Qué ventajas ofrece este flujo de trabajo frente a cargar todos los datos utilizando una herramienta como Pandas?
- 9.5. ¿Qué características del sistema desarrollado permiten incorporar nuevos datos con cambios mínimos?
- 9.6. ¿Qué parte del proceso considera que debería automatizarse en un sistema de producción?
- 9.7. ¿Qué decisiones de diseño fueron importantes para mantener el proyecto reproducible?
- 9.8. ¿Qué aprendió sobre el manejo de datos que no habría sido evidente trabajando únicamente con conjuntos de datos pequeños?

Material a entregar

El trabajo deberá entregarse utilizando el fork realizado durante el laboratorio.

El repositorio deberá contener:

- el código fuente modificado;
- los scripts de descarga;
- las consultas SQL desarrolladas;
- el notebook o notebooks utilizados;
- la documentación de las consultas;
- los scripts utilizados para benchmarks, cuando corresponda;
- el código utilizado para generar los indicadores y visualizaciones;
- el tablero o evidencia del tablero desarrollado;
- un archivo `README.md` con las instrucciones necesarias para reproducir el proyecto.

Los archivos de datos descargados no deberán incluirse dentro del repositorio Git.

El README deberá permitir que una persona que no haya participado en el desarrollo pueda:

- levantar el ambiente;
- descargar los datos;

- ejecutar el análisis;
- reproducir los benchmarks;
- generar los resultados principales.

Evaluación

El laboratorio se evaluará en dos fases. Cada fase tendrá una fecha de entrega independiente.

La primera fase corresponde al Pasaporte del laboratorio. Su propósito es comprobar que el ambiente de trabajo y el sistema inicial de descarga estén funcionando antes de continuar con el análisis.

La segunda fase corresponde al desarrollo y entrega final del laboratorio.

La nota total del laboratorio será de 100 puntos.

Fase 1 – Pasaporte (15 puntos)

Esta fase comprende únicamente los ejercicios 1 y 2.

Para obtener los puntos correspondientes al Pasaporte, el equipo deberá tener un fork funcional del repositorio, levantar correctamente el ambiente y demostrar que su sistema puede obtener los datos iniciales solicitados.

- (5 puntos) Preparación del ambiente.
 - El fork del repositorio fue realizado correctamente.
 - El ambiente puede levantarse utilizando Docker Compose.
 - Los servicios requeridos funcionan correctamente.
 - El procedimiento para levantar el ambiente está documentado en el README.
- (10 puntos) Sistema inicial de descarga.
 - El script proporcionado fue modificado para descargar los datos solicitados.
 - Descarga correctamente los datos de taxis amarillos y verdes correspondientes a 2026.
 - Los archivos se almacenan en la estructura establecida por el proyecto.
 - El sistema identifica los archivos existentes y evita descargarlos nuevamente.
 - Se documentan los cambios realizados al script y el procedimiento utilizado para verificar que la descarga está completa.

El Pasaporte deberá entregarse en la fecha indicada. Los cambios correspondientes a esta fase deberán estar disponibles en el fork al momento de la entrega.

Fase 2 – Entrega final (85 puntos)

Esta fase comprende los ejercicios 3 al 9.

Se evaluará no solamente que las consultas produzcan resultados, sino también la reproducibilidad del análisis, la documentación de las consultas, la interpretación de los resultados y las decisiones tomadas durante el desarrollo.

- (15 puntos) Consultas directas y exploración con DuckDB.
 - Consulta correctamente los archivos Parquet directamente desde DuckDB.
 - Explora la estructura, tipos de datos y contenido del conjunto de datos.
 - Identifica problemas relevantes de calidad de datos.
 - Las consultas utilizadas están documentadas y son reproducibles.
- (15 puntos) Análisis exploratorio.
 - Formula preguntas de análisis relevantes para el conjunto de datos.
 - Construye consultas adecuadas para responderlas.
 - Compara apropiadamente la información de taxis amarillos y verdes.
 - Identifica patrones temporales, diferencias y posibles valores atípicos.
 - Presenta e interpreta al menos tres hallazgos relevantes.
- (10 puntos) Incorporación incremental de datos.
 - El sistema incorpora correctamente los datos de 2024 y, posteriormente, los de 2025.
 - Los datos se obtienen automáticamente desde la fuente original.
 - El sistema evita descargar nuevamente archivos existentes.
 - Las consultas continúan funcionando al incorporar nuevos años o los cambios necesarios están correctamente justificados.
 - El proceso completo puede reproducirse a partir de los scripts desarrollados.
- (15 puntos) Benchmark de Parquet y DuckDB.
 - Construye correctamente la tabla materializada en DuckDB.
 - Utiliza consultas equivalentes para realizar una comparación válida entre ambas estrategias.

- Registra y organiza los tiempos de ejecución.
- Evalúa el comportamiento utilizando diferentes cantidades de datos.
- Interpreta los resultados y explica cuándo resulta conveniente utilizar cada estrategia.
- (15 puntos) Indicadores y visualización.
 - Construye al menos seis indicadores relevantes para el problema.
 - Los indicadores responden preguntas de análisis claramente definidas.
 - Cada indicador está respaldado por una consulta SQL documentada.
 - Las visualizaciones son apropiadas para los datos que representan.
 - El tablero permite analizar los indicadores de manera conjunta.
 - Se justifican los indicadores seleccionados y se interpretan los resultados obtenidos.
- (10 puntos) Análisis completo y discusión.
 - Actualiza correctamente el análisis al incorporar los tres años.
 - Identifica y explica cambios o patrones relevantes entre 2024, 2025 y 2026.
 - Discute las ventajas y limitaciones observadas al utilizar DuckDB y Parquet.
 - Las conclusiones están respaldadas por los resultados obtenidos durante el laboratorio.
- (5 puntos) Reproducibilidad, documentación y versionado.
 - El repositorio se encuentra organizado y contiene los archivos necesarios para reproducir el trabajo.
 - El README contiene instrucciones suficientes para levantar el ambiente, descargar los datos y ejecutar el análisis.
 - Las consultas SQL y transformaciones realizadas se encuentran documentadas.
 - El historial del repositorio evidencia el trabajo realizado durante el desarrollo del laboratorio.
 - Los archivos de datos descargados no fueron incluidos en el repositorio Git.