

Ejercicio 2. Desarrollo del sistema de descarga

2.1 Script proporcionado

El script `scripts/download_data.py` del repositorio base recorre los doce meses de 2026 para taxis amarillos y verdes, pregunta al servidor si cada mes está publicado, omite los archivos que existen y descarga sobre un nombre temporal. Al revisarlo se encontraron cinco problemas.

1. Si la consulta al servidor falla por la red, la función `esta_publicado` devuelve `False` y el mes se reporta como no publicado. Un corte de conexión deja archivos sin descargar y el resumen no lo muestra como error.
2. Después de descargar, el script revisa que el archivo no quede vacío pero no compara los bytes recibidos con el tamaño que informa el servidor. Una transferencia cortada sin error se acepta.
3. Un archivo local se da por bueno si pesa más de cero bytes. Un Parquet dañado o una página de error guardada con ese nombre no se vuelve a descargar.
4. La carpeta de destino es la ruta relativa `data/raw`. Si el script se ejecuta desde otra carpeta, los archivos quedan fuera de la estructura del proyecto.
5. El año está fijo en la constante `ANIO` y en los mensajes. Para descargar 2024 o 2025 hay que editar varias líneas del código.

2.2 a 2.4 y 2.6 Cambios al script

Parte del script	Script proporcionado	Script modificado
Años	Constante <code>ANIO = 2026</code>	Lista <code>ANIOS</code> y opción <code>--anios</code>
Destino	Ruta relativa a la carpeta de trabajo	Ruta calculada desde la ubicación del script, <code>data/raw/tipo/año</code>
Archivo existente	Se omite si pesa más de cero bytes	Se omite si empieza y termina con la marca <code>PAR1</code> de Parquet. Si no la tiene, se descarga de nuevo
Consulta al servidor	Un error de red cuenta como mes no publicado	Un <code>403</code> o <code>404</code> cuenta como no publicado y un error de red como fallido
Tamaño descargado	Se revisa que no sea cero	Se compara con el tamaño que informa el servidor antes de renombrar el archivo temporal, con hasta tres intentos
Mensajes	Año fijo en el texto	Tipo y año de cada archivo
Catálogo de zonas	No se descarga	Se descarga en <code>data/raw/zonas</code> para unir los viajes con distritos y zonas en el ejercicio 4

El resumen final y el código de salida 1 cuando algo falla se conservan del script original.

En este ejercicio `ANIOS` contenía 2026. El ejercicio 5 agregó 2024 y el ejercicio 8 agregó 2025, sin otros cambios al código.

2.5 Ejecución

El script se ejecutó dos veces dentro del servicio lab, la primera con `data/raw` vacía. La salida está en `docs/evidencias/02_descarga_2026.txt`.

Ejecución	Descargados	Ya existían	No publicados	Fallidos
Primera	16	0	8	0
Segunda	0	16	8	0

Laboratorio 8. DuckDB

Javier Eduardo España (23361), Angel Esteban Esquit (23221), Roberto Jose Barreda (23354)

La segunda ejecución no descargó archivos. Los 8 no publicados son septiembre a diciembre de 2026 de cada tipo, que la TLC no había publicado al 6 de octubre de 2026.

Después, verificar_descarga.py dio este resultado.

Tipo	Archivos	Meses	Registros	Tamaño
yellow	8	enero a agosto	29,703,355	511.5 MB
green	8	enero a agosto	337,114	8.3 MB

Los 16 archivos publicados están completos. El detalle por archivo está en docs/evidencias/02_verificacion_descarga.csv, que se reescribe en cada verificación y hoy incluye 2024, 2025 y 2026.

2.7 Cómo se determinó que el conjunto está completo

El script verificar_descarga.py toma los años, los tipos y las rutas de download_data.py y revisa cada archivo en tres pasos.

1. Toma como referencia los archivos enlazados en la página de datos de la TLC, una fuente distinta del servidor que usa la descarga. Para 2026 la página enlaza enero a agosto de yellow y green.
2. Compara los bytes en disco con el tamaño que informa el servidor. Un archivo cortado tiene menos bytes.
3. Lee con DuckDB el pie del Parquet y obtiene su número de registros. Un archivo dañado o una página de error guardada como Parquet falla en este paso.

El script marca como no publicado cualquier Parquet de data/raw que no esté en la lista de la TLC, y termina con código 1 si algún archivo no está completo.

Para probar el criterio se cortó green_tripdata_2026-02.parquet, se borró green_tripdata_2026-03.parquet y se guardó una página de error como yellow_tripdata_2026-09.parquet. La verificación reportó tamaño distinto, falta y no publicado, con 14 de 16 archivos completos. Al ejecutar la descarga, el script detectó el archivo cortado por la falta de la marca PAR1, lo descargó de nuevo junto con el faltante y dejó septiembre como no publicado. Después de borrar la página de error, la verificación volvió a 16 de 16. La salida está en docs/evidencias/02_prueba_errores.txt.